

# メール人材登録 AIモデルフォールバックフロー

supabase/functions/inbound-email/index.ts の実装に基づく。

## 全体フロー概要

```
Outlook受信メール
├─ poll-email (5分ごとpg_cron)
│   └─ inbound-email
│       ├── [STEP1] 関連性チェック (不要メールの早期除外)
│       ├── [STEP2] 重複チェック
│       ├── [STEP3] 添付ファイル抽出 (Word/Excel → テキスト化)
│       ├── [STEP4] Google Driveリンク取得
│       ├── [STEP5] 人材情報抽出 (AI)
│       │   ├── フル解析 (本文+添付テキスト)
│       │   └─ 品質不足時: 本文のみで再解析
│       └─ [STEP6] DB保存 (candidates テーブル)
```

## STEP1: 関連性チェック (`classifyInboundRelevance`)

人材・案件と無関係なメール（自動返信・通知等）を早期除外する。

```
Cerebras 8B (llama3.1-8b)
├─ 成功 → relevant: true/false を返す
└─ 失敗
    └─ Groq 8B (llama-3.1-8b-instant)
        ├── 成功 → relevant: true/false を返す
        └─ 失敗
            └─ Gemini 2.5 Flash Lite (gemini-2.5-flash-lite)
                └─ 成功 → relevant: true/false を返す

relevant: false → スキップ (200 OK で終了)
relevant: true  → STEP2へ
```

### ポイント:

- タイムアウト: 15秒
- 軽量タスクなので Cerebras 8B が有効
- 失敗時は `relevant: true` (スキップせず) にフォールバック

## STEP5: 人材情報抽出 (`generateJSONSmart kind='candidate'`)

氏名・スキル・経歴等を構造化JSON で抽出する。

## 通常パス（フル解析）

```

画像添付あり OR（Cerebras/Groq キーなし）
└─ Gemini 2.5 Flash Lite (gemini-2.5-flash-lite) ※画像対応
    └─ 添付バイナリ+本文で解析

画像添付なし かつ キー設定あり
└─ Groq 8B (llama-3.1-8b-instant)
    ├── 成功 → 結果を返す
    └── 失敗（429 TPD超過 / タイムアウト等）
        └─ Gemini 2.5 Flash Lite (gemini-2.5-flash-lite)
            └─ 成功 → 結果を返す
  
```

### ポイント:

- Cerebras は候補者/案件抽出には不使用（8Bでは複雑な日本語構造化抽出に不足）
- プロンプトには本文（3000文字）+添付テキスト（3000文字）を含む
- Groq の日次トークン上限（500K TPD）はUTC 0:00（JST 9:00）リセット
- **無料枠での処理上限: 約125件/日**（500K ÷ 約4,000トークン/件）

### 品質チェック → 本文のみ再解析

```

フル解析の結果
└─ name が存在 かつ skills > 0 → OK、DB保存へ
    └─ (name なし / "不明") かつ skills = 0 かつ 添付テキストあり
        └─ 本文のみで再解析 (attachments なし・driveTextSection 除去)
            └─ Groq 8B → Gemini（同じフォールバック順）
  
```

### ポイント:

- 添付ExcelやWordが長すぎてAIが混乱する場合に有効
- 本文だけなら氏名・基本情報は取れることが多い

## 自動マッチング（`generateJSONSmart kind='match'`）

人材登録後、案件とのマッチングスコアを自動計算する（`AUTO_MATCH_ENABLED=true` 時）。

```

Cerebras 8B (llama3.1-8b)
└─ 成功 → スコアを返す
    └─ 失敗
        └─ Groq 8B (llama-3.1-8b-instant)
            ├── 成功 → スコアを返す
            └── 失敗
                └─ Gemini 2.5 Flash Lite (gemini-2.5-flash-lite)
                    └─ スコアを返す
  
```

ポイント:

- マッチングはスコア計算のみで軽量タスク → Cerebras 8B が有効
- **match-score** Edge Function (UIからの手動マッチング) も同じフロー

モデル一覧・特性

| モデル                          | 用途                | 無料枠                                   | コンテキスト      |
|------------------------------|-------------------|---------------------------------------|-------------|
| Cerebras llama3.1-8b         | 関連性チェック・マッチングスコア  | 実質無制限                                 | 8K tokens   |
| Groq llama-3.1-8b-instant    | 候補者/案件構造化抽出 (メイン) | 500K tokens/日 (JST 9:00リセット) ≈ 125件/日 | 128K tokens |
| Gemini gemini-2.5-flash-lite | フォールバック・画像解析      | プリペイド制 (要チャージ)                        | 1M tokens   |

Groq 70B (100K TPD = 約25件/日) は2026-05-16に8b-instant (500K TPD = 約125件/日) へ変更済み。

Groq 枯渇時の挙動

Groq → 429 Too Many Requests (日次上限超過・約125件/日)  
└─ Gemini にフォールバック  
    ├─ クレジットあり → 正常動作  
    └─ クレジットなし → 登録失敗 (500エラー)

JST 9:00 に Groq トークンがリセットされると自動復旧。  
125件/日を超える運用が必要な場合は Groq 有料プラン (~\$4/月) または Gemini チャージが必要。

最終更新: 2026-05-16