

AI無料枠の課題と限界

AkiNavi HR-AI における AI 利用コスト・無料枠の制約を整理した資料。
ai_logs テーブルの実績データ（2026年5月）に基づく。

1. 現在のAI構成と無料枠

メール自動取り込み（inbound-email Edge Function）のAI処理は以下の順にフォールバックする。

受信メール

↓

[STEP1] Cerebras llama3.1-8b ← 関連性チェック（スパム除外）

失敗↓

Groq llama-3.1-8b-instant

失敗↓

Gemini gemini-2.5-flash-lite

↓

[STEP5] Groq llama-3.1-8b-instant ← 人材/案件情報の構造化抽出（メイン）

失敗↓

Gemini gemini-2.5-flash-lite ← フォールバック（有料）

各モデルの無料枠

AI	モデル	無料枠	メール換算	リセット
Cerebras	llama3.1-8b	実質無制限	無制限	—
Groq	llama-3.1-8b-instant	500,000 tokens/日	約125件/日	毎日 JST 9:00
Gemini	gemini-2.5-flash-lite	なし（プリペイド制）	チャージ次第	—

※ Groqは2026-05-16に70b（100K TPD = 約25件/日）から8b-instant（500K TPD = 約125件/日）に変更済み。

2. 1メールあたりのトークン消費量

Groqに渡すプロンプトは本文・添付テキストをあわせて最大 約4,300文字 に制限している。

内容	文字数	トークン概算
プロンプトヘッダー（指示文）	約300文字	約150 tokens
メール本文（上限3,000文字）	最大3,000文字	約1,500 tokens
添付テキスト（上限3,000文字）	最大3,000文字	約1,500 tokens
レスポンス（JSON出力）	—	約500 tokens

内容	文字数	トークン概算
合計（最大）	—	約3,500～4,000 tokens/件

添付ファイルが大きい場合の問題

ExcelやWordの添付ファイルが長い場合、プロンプト上限（4,300文字）でトランケート（切り捨て）される。

Excelファイル全文：20,000文字
↓ スマートトランケーション（先頭65% + 末尾35%）
Groqに渡す文字数：4,300文字（残り15,700文字は捨てる）

影響: 氏名・スキルが後半にある場合に抽出漏れが発生する。
その場合は品質チェックで引っかかり「本文のみで再解析」が走るため、**1メール = 最大2回のGroq呼び出し**となる。

3. 実際のメール処理量（ai_logs実績）

日別の処理件数

日付	成功	エラー	合計	状況
5/1	64	14	78	通常
5/9	24	2	26	ポーリング安定化開始
5/10	66	1	67	バックログ消化開始
5/11	420	249	669	バックログ急増
5/12	3,707	755	4,462	ピーク（candidates: 1,518件登録）
5/13	2,541	5	2,546	バックログ継続
5/14	575	786	1,361	Groq/Gemini枯渇
5/15	22	1,252	1,274	ほぼ全滅（下記参照）
5/16	6	3	9	バックログ完了・正常化

5/12のピーク分析:

- 334人のユニーク送信者から計1,518件の人材 + 2,014件の案件を処理
- 1人の送信者が平均10通以上送信（複数の履歴書を一括送付するケース）

足切り（無関係メール除外）の実績

AI種別判断（batch_classify）が有効だった5/12～5/14の3日間において、メール全体に対するスパム・無関係メールの割合を実測できる。

日付	分類対象	人材判定	案件判定	other（足切り）	足切り率
5/12	1,067件	695件	327件	45件	4.2%
5/13	765件	665件	75件	25件	3.3%
5/14	305件	255件	45件	5件	1.6%

結論: 受信メールの **96～98%は人材または案件メール**。スパム・無関係メールはほぼ来ていない。

→ 「数千件のメールから足切り後にいくつ処理するか」という問いに対しては、**足切りはほぼ発生しない（受信＝ほぼ全件処理）** が正確な答えとなる。

注: AI種別判断が無効の期間（5/1～5/11、5/15～5/16）は、送信先アドレスで直接振り分け（human アドレス→人材、projectアドレス→案件）のため足切りなし。この期間の「来たメール=処理するメール」。

4. 5/15 大量エラーの原因分析

5/15 の 1,252件のエラーは**全て同一エラーメッセージ**だった。

```
[GoogleGenerativeAI Error]: 429 Too Many Requests
Your prepayment credits are depleted.
```

エラーが発生したメカニズム

- ① Groqが1日125件（≈500K tokens）を処理し終えて429を返す
↓（トークンを消費しない即時拒否）
- ② Geminiにフォールバック
↓
- ③ Geminiもプリペイドクレジット切れで429
↓
- ④ FAATALエラー → ai_logsに type='unknown' として記録

無限リトライループが状況を悪化させた

poll-emailは処理失敗したメールを**未読に戻して次回再試行**する仕様になっている。

```
失敗メール → 未読に戻す
↓ 5分後
poll-emailが再取得 → また失敗 → 未読に戻す
↓ 5分後
（以下繰り返し）
```

この結果、**同じメールが1日中リトライされ続け**、Groqがリセット（JST 9:00）されても即座に枯渇してしまった。

5/15の時間別エラー数（JST）：

時間帯	unknownエラー
8時	54件
9時（Groqリセット直後）	140件 ← リセットされても即枯渇
10～13時	各120～166件（定常的に失敗継続）

5. 無料枠における1日の処理能力まとめ

現在の構成（2026-05-16時点）

通常メール（テキストのみ・添付なし）

- Groq 8b-instant で処理
- 1件 ≈ 2,000 tokens
- 1日の上限：500,000 ÷ 2,000 = 250件/日

添付ファイルあり（Excel・Word・PDF）

- テキスト抽出後 Groq で処理
- 1件 ≈ 4,000 tokens
- 1日の上限：500,000 ÷ 4,000 = 125件/日

画像添付・スキャンPDF

- Groq非対応のため Gemini 直行
- 無料枠なし（クレジット消費）
- クレジット切れ時は登録失敗

実運用での想定件数（バックログ消化後の通常期）：1日数件～数十件

→ 現状の125件/日で十分な可能性が高い。ただし新規サービス開始直後や大量転送時は超過リスクあり。

6. 課題の優先度整理

課題	深刻度	発生条件	現状
Geminiクレジット切れ	● 高	常時（クレジット未チャージ）	未対処
Groq 125件/日の上限	● 中	1日125件超のメール	バックログ消化後は低リスク
画像・スキャンPDF登録失敗	● 中	画像添付メール受信時	Gemini切れで発生
無限リトライループ	● 中	全AI失敗時	未対処（失敗メールが詰まり続ける）
添付ファイルの文字切り捨て	● 低	長大な添付ファイル	品質チェックで一部補完済み

7. 対策と費用試算

対策A: Geminiクレジットをチャージ（最優先・根本解決）

クレジットがあればGroq枯渇時のフォールバックが機能し、登録失敗がなくなる。

メール量	Gemini費用（概算）
月1,000件（フォールバック分のみ）	約\$1〜2/月
月3,000件（全件Gemini）	約\$10〜15/月

対策B: Groqを有料プランへ（日次上限の撤廃）

モデル	料金	月1,000件での費用
llama-3.1-8b-instant	\$0.06/1M tokens	約\$0.24/月（実質無料）
llama-3.3-70b-versatile	\$0.59/1M tokens	約\$2.4/月

Groq有料プランは日次トークン上限がなくなる。月\$1〜2で実質無制限。

対策C: リトライループ上限の実装（コード修正）

失敗メールのリトライ回数に上限（例：3回）を設け、上限超過で既読にする。
全AIが同時に枯渇する事態でも詰まり続けるメールがなくなる。
→ コード修正のみで対応可能（費用なし）。

推奨対応

短期（すぐできる）： Geminiを\$10チャージ → フォールバック復活

中期（コード修正）： リトライ上限を実装 → 詰まり防止

長期（必要になったら）： Groq有料 or Gemini増額

作成日: 2026-05-16 / データ出典: ai_logs テーブル (Supabase)